

A vertical column of ten blue chevrons pointing upwards is positioned on the left side of the slide.

Aprendizado de Máquina Supervisionado

Membros

Jean Carlos

Jeojildo Pereira

Joaquim Viana



Instrutores

Jean Carlos

Doutorando em Ciência da Computação - UFPA
Mestre em Ciência da Computação - UFPA
Licenciado em Computação - UFPA

Joaquim Viana

Doutorando em Ciência da Computação - UFPA
Mestre em Práticas em Desenvolvimento Sustentável - UFRRJ
Graduação em Ensino de Matemática – Universidade
Pedagógica/Monçambique

Jeojildo Pereira

Mestrando em Ciência da Computação – UFPA
Graduação em *Informatics Engineering* - UTDI



Tópicos



Agenda

- Breve introdução de aprendizado supervisionado
- Árvore de Decisão
 - Estrutura da árvore de decisão;
 - Entropia e ganho de informação
- Redes Neurais Artificiais
 - Neurônio Artificial;
 - *Perceptron* de Múltipla Camadas;
 - *Forword* e *Backpropagation*.
- Matriz de Confusão
- Métricas

Aprendizado de Máquina

Supervisionado



- Os algoritmos de aprendizagem relacionam uma saída com uma entrada com base em dados *rotulados*.


Matematica	Fund_computacao	Tec_computacao	Total	Especialidade
16	22	12	50	metodologias e técnicas de computação
4	16	8	28	engenharia de software
4	13	7	24	sistemas de informação
6	15	11	32	computação gráfica
12	20	11	43	sistemas de computação

Aprendizado de Máquina

Supervisionado



- Os algoritmos de aprendizagem relacionam uma saída com uma entrada com base em dados *rotulados*.



Fonte: <https://www2.decom.ufop.br/terralab/tipos-de-aprendizado-de-maquina-e-algumas-aplicacoes/>


Algoritmos de classificação



- Objetivo é prever uma **classe** ou **rótulo** associado com uma variável de entrada contendo determinados atributos.
- O algoritmo é treinado com um conjunto de dados:
 - classes conhecidas, podendo estes dados estar divididos em somente duas (**classificação binária**) ou em várias classes (classificação multiclasse).

Árvore de Decisão

O que é?



Uma árvore de decisão é utilizado para classificação. Isto é, pode ser usado para prever categorias discretas (sim ou não, por exemplo) e para prever valores numéricos (o valor do lucro em reais).

Árvore de Decisão

Curiosidade



- É um algoritmos mais conhecido entre os algoritmos de *machine learning*;
- A sua estrutura e a composição do algoritmo é similar à de um fluxograma:
 - Etapas fáceis de visualizar e entender.

Árvore de Decisão

Curiosidade



- Além de uma boa técnica com bons resultados, é também uma ótima abordagem para uma compreensão melhor de como funciona o **aprendizado de máquina**.
- O método mais conhecido de ML.
 - Uma árvore pega emprestada uma noção de tomada de decisões que está muito presente em outras áreas, por isso, é mais acessível.

Vou assistir aula na universidade hoje?



Árvore de Decisão



- O grande trabalho da árvore é justamente encontrar os nós que vão ser encaixados em cada posição.
 - Quem será o nó raiz?
 - Depois, quem será o nó da esquerda? E o da direita?
- É preciso realizar alguns importantes cálculos:
 - **Ganho da informação;**
 - **Entropia.**

Árvore de Decisão

Entropia



- A **entropia** é uma medida de incerteza ou impureza em um conjunto de dados.
- No contexto de árvores de decisão, ela quantifica a aleatoriedade ou a desordem dos dados. A fórmula da entropia para um conjunto de dados é:

$$\text{Entropia}(S) = - \sum_{i=1}^n p_i \log_2(p_i)$$

Árvore de Decisão

Ganho da informação



- O **ganho de informação** é uma métrica usada para decidir qual **atributo** deve ser usado para dividir os dados em cada nó da árvore.
- Ele mede a redução na entropia ao dividir os dados com base em um atributo. A ideia é escolher o atributo que resulta na maior redução de incerteza.

$$\text{Ganho de Informação}(S, A) = \text{Entropia}(S) - \sum_{v \in \text{Valores}(A)} \frac{|S_v|}{|S|} \text{Entropia}(S_v)$$

Árvore de Decisão

Exemplos de aplicações



- Diagnóstico de doenças;
 - Identificar doenças a partir de informações cedidas ao algoritmo como treinamento.
- Previsão de empréstimos;
 - **Esse é um problema de regressão, pois requer uma informação numérica como saída.** O sistema vai entender como a base de dados está organizada de acordo com os atributos e criar um modelo capaz de fazer essa previsão.



Árvore de Decisão


Exemplos de aplicações



- Análise de sentimentos;
 - Não é incomum ver também aplicações na área da análise de sentimentos, subcategoria do campo de **PLN**.
- Previsão de saída de funcionários;
 - O RH saber quando um funcionário está quase saindo da empresa por insatisfação. Com a análise de dados sobre cada um, o modelo entende a base de dados e consegue realizar uma predição, ou seja, uma classificação.

Outros algoritmos de classificação






KNN

Support Vector Machine



SVM

Support Vector Machine



Preparação dos dados



Preparação

Divisão da base: Treino e teste



- Os dados de **treinamento** são empregados na indução e no **ajuste** do modelo.
- Os de **teste** simulam a apresentação de **objetos novos** ao preditor, os quais **não foram vistos em sua indução**.
- Os dados são divididos em conjuntos de treino e teste.
 - Geralmente utiliza 80% dos dados para treino e 20% para teste.

Exemplo

Processo de treinamento



Realização do Teste




Avaliação dos Modelos


Desempenho




- Subconjuntos são disjuntos para assegurar que as medidas de desempenho sejam obtidas a partir de um conjunto de exemplos diferente daquele usado no aprendizado.
- Alguns dos principais métodos de amostragem existentes, são:




(a) *Holdout*



(b) *Amostragem aleatória*



(c) *Validação cruzada*



(d) *Bootstrap*



- No caso dos procedimentos que envolvem médias de desempenho, devem-se reportar também os valores de **desvio padrão** associados.
- Para reportar **estimativas** mais precisas do **desempenho** esperado do algoritmo nesses casos, deve-se então apresentar algum intervalo de confiança para a média calculada, que irá envolver também o desvio padrão obtido.



De maneira geral, isso é realizado pela comunidade reportando ao menos os valores de média e desvio padrão dos experimentos realizados.

Importante!



Métricas





Tabela 10.1 Matriz de confusão para um problema com duas classes

		Classe predita	
		+	-
Classe verdadeira	+	VP	FN
	-	FP	VN

Matriz de confusão

- **VP** corresponde ao número de **verdadeiros positivos**, ou seja, o número de exemplos da classe positiva classificados corretamente.
- **VN** corresponde ao número de **verdadeiros negativos**, ou seja, o número de exemplos da classe negativa classificados corretamente.
- **FP** corresponde ao número de **falsos positivos**, ou seja, o número de exemplos cuja classe verdadeira é negativa, mas que foram classificados incorretamente como pertencentes à classe positiva.
- **FN** corresponde ao número de **falsos negativos**, ou seja, o número de exemplos pertencentes originalmente à classe positiva que foram incorretamente preditos como da classe negativa.



$$n = VP + VN + FP + FN$$

Acurácia total: calculada pela soma dos valores da diagonal principal da matriz, dividida pela soma dos valores de todos os elementos da matriz

$$Acurácia = \frac{VP + VN}{N}$$

Precisão: proporção de exemplos positivos classificados corretamente entre todos aqueles preditos como positivos

$$Precisão = \frac{VP}{VP + FP}$$

Recall: corresponde à taxa de acerto na classe positiva. Também é chamada de taxa de verdadeiros positivos

$$Recall = \frac{VP}{VP + FN}$$

F1-score: Essa métrica representa a média harmônica entre as métricas de Precisão e de Recall.

$$f1 - score = \frac{2 * Precisão * Recall}{Precisão + Recall}$$



Título

Subtítulo



Colocar em Prática



[Link para notebook Colab](#)







Contate-nos



lid@ufpa.br



@lid.ufpa