



Regressão


Atílio Azevedo

Helder Matos

Joaquim Viana

Rodrigo Silva

Tipos de aprendizado





Agenda

- Regressão
- Regressão Linear
- Regressão Múltipla
- Regressão Logística
- Random Forest Regression

Implemente essa base de dados



Bairro	Área	Número de quartos	Preço
Pedreira	45m ²	1	45.000 R\$
Tapanã	77m ²	1	55.000 R\$
Telégrafo	120m ²	2	84.000 R\$
Barreiro	140m ²	3	88.000 R\$
Guamá	255m ²	4	145.000 R\$
Nazaré	208m ²	4	155.000 R\$
Marco	170m ²	5	122.000 R\$



O que é um problema de regressão?

- Um problema de regressão se refere à tarefa de modelar um ou mais variáveis dependentes utilizando um conjunto de variáveis preditores (ou independentes). - ScienceDirect



Implemente essa base de dados




Preditores/Var. Independentes

Var. dependente/ de saída

Bairro	Área	Número de quartos	Preço
Pedreira	45m ²	1	45.000 R\$
Tapanã	77m ²	1	55.000 R\$
Telégrafo	120m ²	2	84.000 R\$
Barreiro	140m ²	3	88.000 R\$
Guamá	255m ²	4	145.000 R\$
Nazaré	208m ²	4	155.000 R\$
Marco	170m ²	5	122.000 R\$

- O objetivo da resolução de um problema de regressão é encontrar o mínimo global;
- Para isso, devem ser encontrados coeficientes que minimizam a função de custo (ou Loss Function).





Exemplos de problemas de regressão

- Preços de imóveis;
-

Regressão Linear

Fórmulas principais



$$Y_i = \theta_0 + \theta_1 X_i + \epsilon_i$$

$$\epsilon_i = Y_i - \hat{Y}_i$$

Regressão Linear

Fórmulas principais



Fórmula para encontrar o *slope*

$$\hat{\theta}_1 = \frac{\sum_{i=1}^m (x^{(i)} - \bar{\mathbf{x}})(y^{(i)} - \bar{\mathbf{y}})}{\sum_{i=1}^m (x^{(i)} - \bar{\mathbf{x}})} \quad \text{Ou} \quad \hat{\theta}_1 = \frac{(\overline{\mathbf{xy}}) - (\bar{\mathbf{x}})(\bar{\mathbf{y}})}{\overline{\mathbf{x}^2} - \bar{\mathbf{x}}^2}$$

Fórmula para encontrar o intercepto

$$\hat{\theta}_0 = \bar{\mathbf{y}} - \hat{\theta}_1 \bar{\mathbf{x}}$$

Regressão Linear

Função de custo



MSE (Mean Squared Error)

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

MAE (Mean Absolute Error)

$$MAE = \frac{1}{n} \sum_{i=1}^n |\hat{y}_i - y_i|$$

RMSE (Root-Mean Squared Error)

$$RMSE = \sqrt{\sum_{i=1}^n \frac{(\hat{y}_i - y_i)^2}{n}}$$

Regressão Linear

Pontos principais



Bairro	Área	Número de quartos	Preço
Pedreira	45m ²	1	45.000 R\$
Tapanã	77m ²	1	55.000 R\$
Telégrafo	120m ²	2	84.000 R\$
Barreiro	140m ²	3	88.000 R\$
Guamá	255m ²	4	145.000 R\$
Nazaré	208m ²	4	155.000 R\$
Marco	170m ²	5	122.000 R\$

$$\bar{x} = 145$$

$$\bar{y} = 99.142$$

Regressão Linear

Pontos principais



Bairro	Área	Número de quartos	Preço
Pedreira	45m²	1	45.000 R\$
Tapanã	77m²	1	55.000 R\$
Telégrafo	120m²	2	84.000 R\$
Barreiro	140m²	3	88.000 R\$
Guamá	255m²	4	145.000 R\$
Nazaré	208m²	4	155.000 R\$
Marco	170m²	5	122.000 R\$

$$\hat{\theta}_1 = \frac{\sum_{i=1}^m (x^{(i)} - \bar{x})(y^{(i)} - \bar{y})}{\sum_{i=1}^m (x^{(i)} - \bar{x})}$$

562

Regressão Linear

Pontos principais



Bairro	Área	Número de quartos	Preço
Pedreira	45m²	1	45.000 R\$
Tapanã	77m²	1	55.000 R\$
Telégrafo	120m²	2	84.000 R\$
Barreiro	140m²	3	88.000 R\$
Guamá	255m²	4	145.000 R\$
Nazaré	208m²	4	155.000 R\$
Marco	170m²	5	122.000 R\$

$$\hat{\theta}_0 = \bar{y} - \hat{\theta}_1 \bar{x}$$

17566

Regressão Linear

Pontos principais



Bairro	Área	Número de quartos	Preço
Pedreira	45m²	1	45.000 R\$
Tapanã	77m²	1	55.000 R\$
Telégrafo	120m²	2	84.000 R\$
Barreiro	140m²	3	88.000 R\$
Guamá	255m²	4	145.000 R\$
Nazaré	208m²	4	155.000 R\$
Marco	170m²	5	122.000 R\$

$$\hat{Y}_i = \theta_0 + \theta_1 X_i$$

$$\hat{Y}_i = 17566 + 562X_i$$

Regressão Linear

Pontos principais



Bairro	Área	Número de quartos	Preço
Pedreira	45m²	1	45.000 R\$
Tapanã	77m²	1	55.000 R\$
Telégrafo	120m²	2	84.000 R\$
Barreiro	140m²	3	88.000 R\$
Guamá	255m²	4	145.000 R\$
Nazaré	208m²	4	155.000 R\$
Marco	170m²	5	122.000 R\$

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

122943837

$$RMSE = \sqrt{\sum_{i=1}^n \frac{(\hat{y}_i - y_i)^2}{n}}$$

11088

Regressão Múltipla

Pontos principais



- A regressão múltipla utiliza da mesma proposta da Regressão Linear, porém com mais de uma variável independente.
- A diferença na fórmula é representada da seguinte maneira:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \varepsilon$$

Regressão Múltipla

Encontrando Theta



Bairro	Área	Número de quartos	Preço
Pedreira	45m²	1	45.000 R\$
Telégrafo	120m²	2	84.000 R\$
Barreiro	140m²	3	88.000 R\$

1	1	1
45	120	140
1	2	3

1	45	1
1	120	2
1	140	3

$$\theta = (X^T X)^{-1} X^T Y$$

=

X	X	X	-1
X	X	X	
X	X	X	

Regressão Múltipla

Encontrando Theta



1	1	1
45	120	140
1	2	3

45.000
84.000
88.000

=

Y
Y
Y

$$\theta = (X^T X)^{-1} X^T Y$$

X	X	X
X	X	X
X	X	X

-1

Y
Y
Y

=

$$\theta = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \end{bmatrix}$$

Gradiente Descendente


Pontos principais



- Função de otimização que procura iterativamente diminuir a função de custo ajustando os parâmetros theta;
- Normalmente é um hiperparâmetro representado por alfa.

$$\theta_0 = \theta_0 - \alpha \cdot \frac{2}{m} \sum_{i=1}^m error^{(i)}$$

$$\theta_1 = \theta_1 - \alpha \cdot \frac{2}{m} \sum_{i=1}^m error^{(i)} \cdot \mathbf{x}^{(i)}$$




Regressão Logística

Pontos principais



- Trabalha com regressão para classificação de dados;
- Os outputs são probabilidades que serão divididos de maneira binária (0 ou 1), com 1 sendo a classe procurada e 0 quaisquer outras classes se houverem mais de 2.




Random Forest Regression

Pontos principais




- Método Ensemble que utiliza de várias árvores de decisão para formar uma “floresta” robusta.
- Versátil e bem utilizável para problemas com dimensões variadas.



Random Forest Regression

Pontos principais




Discretização




Exemplos de discretização na vida real:

- IMC;



Random Forest Regression

Pontos principais



Random Forest Regression

Pontos principais



Conceitos utilizados para Random Forest Regression:

- BootStrapping Aggregating (Bagging);
- MSE;
- Feature Selection