


A vertical column of ten blue chevrons pointing upwards is positioned on the left side of the slide.

Aprendizado de Máquina Não-Supervisionado

Samara Souza

Heloísa Silva

Helder Matos



Agenda

- Introdução ao Aprendizado Não-Supervisionado
- Clusterização
 - K-Means
 - PCA
- Prática



Instrutores

Samara Souza

Doutoranda em Ciência da Computação - UFPA
Mestra em Ciência da Computação - UFPA
Bacharel em Sistemas de Informação - UFPA



Heloísa Silva

Graduanda em Ciência da Computação - UFPA
Bolsista de Iniciação Científica



Helder Matos


Mestrando em Ciência da Computação - UFPA
Bacharel em Ciência da Computação - UFPA

Aprendizado Não-Supervisionado

Definições



- O Aprendizado de Máquina Não-Supervisionado envolve algoritmos que **encontram padrões ocultos** nos dados **sem rótulos ou informações prévias**.
- Ao contrário do aprendizado supervisionado, não há **respostas pré-definidas**. O modelo deve descobrir **padrões** por conta própria.




Aprendizado Não-Supervisionado

Definições



- **Objetivo:** Identificar estruturas ocultas nos dados. Isso pode revelar insights valiosos e inesperados.



Aprendizado Não-Supervisionado

Tarefas Principais



Agrupamento (Clustering)

Organiza dados em grupos com características semelhantes para insights de segmentação.



Detecção de Outliers

Identifica pontos de dados incomuns que podem indicar falhas ou fraudes.



Redução da Dimensionalidade

Diminui a complexidade dos dados mantendo a informação essencial.



Regras de Associação


Descobre padrões frequentes em conjuntos de dados transacionais para insights de mercado.

Clusterização (Clustering)

Definições



- É uma técnica de aprendizado não supervisionado que **agrupa** um conjunto de objetos em **clusters**, de forma que objetos dentro do mesmo cluster sejam mais **semelhantes entre si** do que aqueles em clusters diferentes.




Clusterização (Clustering)

Aplicações



- Segmentação de mercado
- Encontrar grupos de clientes que irão comprar um produto
- Agrupamento de documentos/notícias
- Agrupamento de produtos similares
- Perfis de clientes (Netflix)
- Análise de redes sociais




K-means

Algoritmos de Clusterização populares




- Agrupa dados em **k** clusters, onde **k** é definido previamente. Os pontos são atribuídos ao cluster mais próximo, com base na média dos pontos do cluster (centróide).
- Etapas:
 1. Escolher '**K**' clusters.
 2. Atribuir pontos ao cluster mais próximo.
 3. Recalcular o centróide de cada cluster.
 4. Repetir até convergência.




K-means

Algoritmos de Clusterização



K-means

Algoritmos de Clusterização




K-means

Definição da quantidade de clusters



**Como identificar a quantidade
“ideal” de clusters?**



K-means

Método Elbow



- O **método Elbow** é uma técnica visual usada para encontrar o número ideal de clusters (K) ao realizar a clusterização com o algoritmo K-Means.

Como funciona?


- Executa-se o K-Means para diferentes valores de K (número de clusters).
- Calcula-se a soma dos **erros quadráticos** dentro de cada cluster para cada valor de K.
- **Erro Quadrático Médio (Inertia/Within-Cluster-Sum of Squares):** Mede a soma das distâncias dos pontos até o centro de seu respectivo cluster.
- Os resultados são plotados em um gráfico.

K-means

Método Elbow



Elbow method



K-means

Análise e Interpretação dos Clusters - K-means



- **Distância Euclidiana:** Usada para medir a proximidade dos pontos aos centróides.
- **Interpretação dos resultados:**
 - **Dentro dos clusters:** Alta similaridade entre os pontos.
 - **Entre clusters:** Diferenciação clara entre grupos.
- **Vantagens:**



Simplicidade e eficiência em grandes conjuntos de dados.
- **Desvantagens:**
 - Os dados devem ser numéricos e comparáveis por distância.
 - K-means é sensível a outliers (pontos que não pertencem a nenhum cluster), que podem distorcer a posição do centróide e estragar o agrupamento.

Algoritmos de Clusterização

Outros Algoritmos



- **DBSCAN:** Agrupa pontos densamente conectados, detectando automaticamente outliers e clusters de forma arbitrária.
- **Hierarchical Clustering:** Cria uma árvore de clusters (dendrograma), usando fusões ou divisões sucessivas de grupos.




Principal Component Analysis(PCA)

Algoritmos de Clusterização populares




- **O PCA(Principal Component Analysis)** é uma técnica de redução de dimensionalidade(atributos) que transforma os dados originais em um novo conjunto de variáveis **(componentes principais)** enquanto tenta preservar a estrutura do cluster.



Aplicação de PCA nos dados Iris

Principal Component Analysis(PCA)

Algoritmos de Clusterização populares



Principal Component Analysis(PCA)

Análise e Interpretação dos Clusters - PCA



- **Funcionamento:**

- Calcula as componentes principais com base na variância dos dados.
- Transforma os dados para um novo espaço dimensional, onde os eixos representam a direção de maior variação.

- **Vantagens:**

- Reduz a dimensionalidade sem perda significativa de informação.
- Melhora a eficiência e a visualização dos dados.

- **Desvantagens:**

- Pode ser difícil interpretar os novos componentes, que são combinações lineares das variáveis originais.

Sessão prática

Hands On




Vamos colocar em prática?

<https://bit.ly/lid-cluster>



Recomendações

Fique Ligado!





Contate-nos



lid@ufpa.br



@lid.ufpa