




Aprendizado por regras associativas

Helder Matos

Heloísa Silva

Samara Souza



Agenda

- Regras Associativas
 - Mineração de itemsets frequentes
 - Geração de regras associativas
 - Métricas
- Prática



Instrutores

Samara Souza

Doutoranda em Ciência da Computação - UFPA
Mestra em Ciência da Computação - UFPA
Bacharel em Sistemas de Informação - UFPA



Heloísa Silva

Graduanda em Ciência da Computação - UFPA



Helder Matos

Mestrando em Ciência da Computação – UFPA
Bacharel em Ciência da Computação – UFPA

Introdução às regras associativas

Cervejas e fraldas?



- Objetivo: determinar **associações** entre itens de alguma relação.
- Utilizamos a **frequência dos conjuntos dos itens** para quantificar associações.
- Surgiu no contexto de Market Basket Analysis:
 - **Transações**: itens comprados por clientes.
 - **Itemsets**: conjuntos de itens descobertos.
 - **Regras de associação**: $X \Rightarrow Y$ (X implica em Y).
- Exemplo famoso: “quem compra cerveja também compra fraldas” 🤔



Aplicações

Regras na prática



Market Basket Analysis (MBA)

Análise de padrões de compra para otimizar layouts de loja e promoções.



Sistemas de Recomendação

Sugestões personalizadas de produtos em plataformas de e-commerce, redes sociais e mídias digitais.



Bioinformática

Identificação de padrões em sequências genéticas e interações proteicas.



Análise de Logs Web

Compreensão do comportamento do usuário e otimização de sites.

Mineração de itemsets frequentes

Minerando itemsets



- Seja uma base de dados T , com n transações.
- Cada transação é obtida de um conjunto universo de itens U .
- As transações são binarizadas, em geral.
- Um *itemset* é um conjunto de itens arbitrários.
- Um k -itemset é um itemset com k itens.
- O número de transações em que um itemset ocorre como subconjunto é a quantificação de sua frequência, ou seu suporte.

Universo de itens U



TID	Transação
1	  
2	 
3	   

1-itemsets	     
2-itemsets	     
3-itemsets	     
4-itemsets	       
5-itemsets	     

Mineração de itemsets frequentes

Definições



- **TID**: Transaction ID, uma identificação da transação.
- **Suporte**: o suporte de um itemset I é a fração de transações em T que contém I como subconjunto.
- **Mineração de Itemsets frequentes (FIM)**: determinar todos os itemsets frequentes I que ocorrem como subconjunto de pelo menos uma fração mínima pré-definida, conhecida como **suporte mínimo**.
- Exemplo: na tabela, o suporte de {🍉 🍌} é $\frac{3}{5} = 0.6$, {🍉 🍌 🍇} é $\frac{2}{5} = 0.4$, {🥑 🍇} é $\frac{1}{5} = 0.2$.


TID	Transação
1	{🍏 🍊 🍌}
2	{🍉 🍌 🍇}
3	{🍏 🥑 🍉 🍌}
4	{🍉 🍌 🍇}
5	{🥑 🍌 🍇}

Mineração de itemsets frequentes

Propriedades dos itemsets frequentes



- **Monotonicidade:** o suporte de todo subconjunto J de I é pelo menos igual ao suporte de I .
- **Fechamento Descendente:** todo subconjunto de um FI também é frequente.
- **FI máximo:** FIs que não tem superconjuntos frequentes.
- **Lattice de itemsets:** estrutura hierárquica usada para organizar todos os possíveis itemsets em um conjunto de dados (2^n-1).




Algoritmos de FIM

Apriori



- **Apriori**: usa o fechamento descendente para podar o espaço de busca de candidatos.
 - Gera candidatos com k de baixa ordem.
 - Usa o fechamento para eliminar infrequentes.
 - Geração de candidatos e contagem de suporte para itemsets de ordem $k+1$ são intercalados.
- A contagem de suporte é a operação mais cara: depende do tamanho do conjunto de dados de transações.

```
Algorithm Apriori(Transactions:  $\mathcal{T}$ , Minimum Support:  $minsup$ )
begin
   $k = 1$ ;
   $\mathcal{F}_1 = \{ \text{All Frequent 1-itemsets} \}$ ;
  while  $\mathcal{F}_k$  is not empty do begin
    Generate  $\mathcal{C}_{k+1}$  by joining itemset-pairs in  $\mathcal{F}_k$ ;
    Prune itemsets from  $\mathcal{C}_{k+1}$  that violate downward closure;
    Determine  $\mathcal{F}_{k+1}$  by support counting on  $(\mathcal{C}_{k+1}, \mathcal{T})$  and retaining
      itemsets from  $\mathcal{C}_{k+1}$  with support at least  $minsup$ ;
     $k = k + 1$ ;
  end;
  return( $\bigcup_{i=1}^k \mathcal{F}_i$ );
end
```




Algoritmos de FIM

Enumeração de árvores



- **Árvore de enumeração**: estrutura que gera os itemsets candidatos.
- É um subgrafo da lattice de itemsets.
- Os itemsets são gerados seguindo uma estratégia de **crescimento** da árvore.
- Necessita de uma ordem lexicográfica.
- Vantagem: gera uma representação abstrata e hierárquica dos itemsets.



Algorithm *GenericEnumerationTree*(Transactions: $\mathcal{T}$,
Minimum Support: $minsup$)

```
begin
  Initialize enumeration tree  $\mathcal{ET}$  to single Null node;
  while any node in  $\mathcal{ET}$  has not been examined do begin
    Select one of more unexamined nodes  $\mathcal{P}$  from  $\mathcal{ET}$  for examination;
    Generate candidates extensions  $C(P)$  of each node  $P \in \mathcal{P}$ ;
    Determine frequent extensions  $F(P) \subseteq C(P)$  for each  $P \in \mathcal{P}$  with support counting;
    Extend each node  $P \in \mathcal{P}$  in  $\mathcal{ET}$  with its frequent extensions in  $F(P)$ ;
  end
  return enumeration tree  $\mathcal{ET}$ ;
end
```

Algoritmos de FIM

Outros métodos e algoritmos



- **ECLAT**: encontra conjuntos de itens frequentes usando interseção de transações, sendo eficiente para dados esparsos e grandes volumes de itens.
- **VIPER**: encontra padrões frequentes com recuperação eficiente, usando uma abordagem vertical para identificar padrões em grandes volumes de dados.
- **FP-Growth**: otimiza a busca criando a FP-Tree e concatena itens frequentes usando divisão e conquista.
- **FP-Max**: encontra os conjuntos frequentes máximos e usa um array para otimizar em dados esparsos.
- **H-Mine**: usa H-Struct para encontrar itens frequentes e resolver problemas de memória e escalabilidade em dados densos e esparsos.

Geração de regras associativas

Regras e confiança



- **Confiança**: é a probabilidade condicional de uma transação conter o itemset Y , dado que essa transação contenha o itemset X .
- A confiança é também conhecida como a razão entre o suporte de $X \cup Y$ e o suporte de X .
- X é conhecido como **antecedente** e Y como **consequente**.
- **Limiar de confiança mínimo**: usado para gerar as regras mais relevantes.




Geração de regras associativas

Se X acontece, então Y acontece




- **Regras associativas:** relações de causa e efeito $X \Rightarrow Y$ onde o **suporte de $X \cup Y$** é menor ou igual a um suporte mínimo e sua **confiança** seja menor ou igual a um **limiar de confiança mínimo**.
 - existe um número suficiente de transações relevantes para a regra.
 - a regra deve ter força suficiente em termos de probabilidades condicionais.



Geração de regras associativas

Framework de geração de regras



- A fase 1 é mais complexa.
- A fase 2 é mais direta.
- **Monotonicidade da confiança:** sejam os FIs $A \subset B \subset C$, a confiança de $B \Rightarrow C - A$ é menor ou igual a confiança de $A \Rightarrow C - A$.
- Exemplo: o suporte de $\{\text{🍏}\} \Rightarrow \{\text{🍊 🍌}\}$ é o mesmo de $\{\text{🍏 🍊}\} \Rightarrow \{\text{🍌}\}$, porém a confiança da primeira regra é maior. Logo a segunda é redundante.

Métricas de avaliação de ARM

Como medir a importância de uma regra?



Métrica	Descrição	Fórmula	Intervalo
Support	Combina o suporte do antecedente A e do consequente B	$support(A \rightarrow C) = support(A \cup C)$	[0,1]
Confidence	Probabilidade condicional de acontecer C, dado que A aconteceu	$confidence(A \rightarrow C) = \frac{support(A \cup C)}{support(A)}$	[0,1]
Lift	Probabilidade de ocorrência de $A \Rightarrow C$, se ambos forem eventos independentes	$lift(A \rightarrow C) = \frac{confidence(A \rightarrow C)}{support(C)}$	[0,∞]
Leverage	Mede o quanto A e C apareceriam juntos, se ambos fossem eventos independentes	$leverage(A \rightarrow C) = support(A \cup C) - support(A) \times support(C)$	[-1,1]
Conviction	Mede o quanto o consequente é dependente do antecedente	$conviction(A \rightarrow C) = \frac{1 - support(C)}{1 - confidence(A \rightarrow C)}$	[0,∞]
Zhang's metric	Mede o nível de associação (zhang > 0) e desassociação (zhang < 0)	$num = confidence(A \rightarrow C) - confidence(A' \rightarrow C)$ $den = Max[confidence(A \rightarrow C), confidence(A' \rightarrow C)]$ $zhang(A \rightarrow C) = \frac{num}{den}$	[-1,1]

Regras da vida real


Regras encontradas em um supermercado de Belém



#	Antecedentes	Consequentes	Confiança	Suporte	Lift
1	PRESUNTO SADIA PERU COZ P/FAT KG (6,9); MUSCULO MOIDO KG	QUEIJO MUSSARELA P/FATIAZ KG (25,920)	0.64035	0.00141	9.54033
2	SALADA FRUTAS C/CREME KG	BUFFET C/ACOMPANHAMENTO kg	0.58025	0.00204	27.22358
3	AGUA MINERAL GELADA	BUFFET C/ACOMPANHAMENTO kg	0.40050	0.00323	18.79031
4	AMPICILINA EMS 500MG C/12 COMP (G)	MAC NISSIN LAMEN GAL.CAIPIRA 85G	0.39510	0.00162	54.63186
5	MANTEIGA PIRACANJUBA C/SAL POTE 500G	TOALHA PAPEL SCALA BRANCO 60FL C/2	0.18597	0.00145	5.53670
6	CREME LEITE ITALAC T/P 200g	QUEIJO MUSSARELA P/FATIAZ KG (25,920)	0.18268	0.00122	2.72172
7	FANTA LARANJA LATA 350ML	CALMAN ATIVUS C/20 DRG	0.16526	0.00117	7.58300
8	LEITE LIQ ITALAC INTEGRAL 1L	QUEIJO MUSSARELA P/FATIAZ KG (25,920)	0.16391	0.00214	2.44197
9	FEIJAO PRETO GAMA LOPES 1kg	CHARQUE PA INDEPENDENCIA (6X5) KG	0.13571	0.00120	9.40999
10	COCA COLA PET 2LT	QUEIJO MUSSARELA P/FATIAZ KG (25,920)	0.12281	0.00302	1.82969

Material adicional

Recomendações sobre recomendações



[Data Mining: The Textbook](#)

Sessão prática

Criando um sistema de recomendação



POBREFLIX

M ALTA



la: A Lenda d...



The Umbrella Acad...



SCOOPY! O Filme



Contate-nos



lid@ufpa.br



[@lid.ufpa](https://www.instagram.com/@lid.ufpa)