

Machine Learning Crash Course: Hands-on with Python

Agenda

1. Planejamento do curso
2. Introdução ao aprendizado de máquina
3. Tipos de aprendizado
4. Manipulação, análise e visualização
5. *Hands-on with Python*

Introdução ao aprendizado de máquina

- **Disclaimer**


- **Aprendizado de máquina**
- Aprendizagem de máquina
- Aprendizado automático
- **Aprendizado por experiência**
- Aprendizagem automática
- ...



Introdução ao aprendizado de máquina



Arthur Samuel
(1901–1990)



“[...] Dar ao computador a capacidade de **aprender** sem ser explicitamente programado. [...]”

Introdução ao aprendizado de máquina

- **Definição de aprendizado indutivo**
 - Permite a generalização de uma propriedade para um conjunto infinito de elementos
- **Definição de indução**
 - Operação mental que consiste em se estabelecer uma **verdade universal** (proposição geral) com base no **conhecimento** de certo número de dados singulares
- É análogo ao método de prova matemática por indução

Introdução ao aprendizado de máquina

- **Três etapas para a prova por indução matemática**
 - **Base indutiva:** elege-se um subconjunto de elementos do conjunto e demonstra-se que a propriedade é válida para eles
 - **Hipótese indutiva:** admite-se que a propriedade é válida para subconjuntos que contenham elementos utilizados na base de indução (feito de maneira recorrente)
 - **Passo indutivo:** a propriedade continuará sendo válido quando se acrescenta mais um elemento ou subconjunto de elementos

Introdução ao aprendizado de máquina

- Exemplo de uma igualdade provada por indução matemática
- Queremos provar que

$$P(n) = \sum_{i=0}^n i = \frac{n(n+1)}{2}$$

Introdução ao aprendizado de máquina

- 1º passo: base indutiva, considerando $n = 0$

$$P(0) = \sum_{i=0}^0 i = \frac{0(0+1)}{2} = 0$$

Introdução ao aprendizado de máquina

- 2º passo: hipótese indutiva, considerando $n = k$

$$P(k) = \sum_{i=0}^k i = \frac{k(k+1)}{2}$$


Introdução ao aprendizado de máquina

- **3º passo:** passo indutivo, considerando $n = k+1$

$$\begin{aligned}P(k+1) &= \sum_{i=0}^k i + (k+1) = \frac{k(k+1)}{2}(k+1) \\&= \sum_{i=0}^{k+1} i = \frac{k(k+1) + 2(k+1)}{2} \\&= \sum_{i=0}^{k+1} i = \frac{(k+1) + ((k+1) + 1)}{2}\end{aligned}$$

Introdução ao aprendizado de máquina

- No contexto do aprendizado de máquina, a indução é uma forma de **inferência lógica** que permite obter **conclusões** genéricas sobre um conjunto particular de **premissas** (exemplos)
- É um aprendizado que inicia **da parte para o todo**



Remete a uma
base de dados!

Introdução ao aprendizado de máquina


- Exemplo: para um conjunto de objetos, $X = \{a, b, c, d, \dots\}$, se a propriedade P é verdade para a , e se P é verdade para b , e se P é verdade para c , ... então P é verdade para todo X
 - Caso 1:
 - José é aluno
 - José come no RU
 - Caso 2:
 - Maria é aluna
 - Maria come no RU
 - Caso 3:
 - Luis é aluno
 - Luis come no RU

Lei geral: alunos comem no RU.

Introdução ao aprendizado de máquina

- A hipótese indutiva **pode ou não** preservar a verdade
 - Número de exemplos significativo (**tamanho da base de dados**)
 - Quantos alunos foram avaliados? É significativo?
 - Espaço amostral representativo (**estratificação**)
 - E se o espaço amostral fosse apenas de alunos que jantam no RU?
 - Qualidade dos exemplos (**outliers**)
 - E se as amostras fossem de alunos que frequentam a universidade as quartas-feiras apenas? Ou somente mulheres?

Tipos de aprendizado



Tipos de aprendizado

- O aprendizado indutivo pressupõe uma **base de dados**

Feature ou característica ou dimensão ou coluna

	Atributo 1	Atributo 2	Atributo 3	...	Atributo m	
Linha 1	$x_{1,1}$	$x_{1,2}$	$x_{1,3}$	...	$x_{1,m} = y_1$	$\equiv (\vec{x}_1, y_1)$
Linha 2	$x_{2,1}$	$x_{2,2}$	$x_{2,3}$	...	$x_{2,m} = y_2$	$\equiv (\vec{x}_2, y_2)$
	$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	
Linha n	$x_{n,1}$	$x_{n,2}$	$x_{n,3}$	...	$x_{n,m} = y_n$	$\equiv (\vec{x}_n, y_n)$

Classe ou rótulo ou target

Amostra ou exemplo

Tipos de aprendizado

- Exemplos de base de dados
 - <https://archive.ics.uci.edu/>
 - <https://www.kaggle.com/datasets>
 - <https://data.un.org/>
 - <https://cs.joensuu.fi/sipu/datasets/>
 - <https://basedosdados.org/>
 - <https://brasil.io/datasets/>
 - <https://portal.datransparencia.gov.br/download-de-dados>



Aprendizado supervisionado

Aprendizado supervisionado


- Trabalha com exemplos de treinamento oriundos da base de dados
- Cada amostra é descrita como

$$([x_{i,1}, x_{i,2}, x_{i,3}, \dots, x_{i,m}], y_i) = (\vec{x}_i, y_i)$$


- **Objetivo do aprendizado:** construir um **modelo computacional** que determine corretamente a classe de novos exemplos ainda não rotulados

Aprendizado supervisionado


- **Rótulo discreto**: problema de classificação



Linearmente separável






Linearmente não-separável



Aprendizado supervisionado

- **Rótulos contínuos**: problema de regressão



Aprendizado não-supervisionado

Aprendizado não-supervisionado



- Analisa exemplos fornecidos e tenta determinar se alguns deles podem ser **agrupados** (clusterizados) de alguma maneira
- Cada amostra é descrita como

$$(x_{i,1}, x_{i,2}, x_{i,3}, \dots, x_{i,m}) = \vec{x}_i$$

- Um especialista geralmente é requisitado para determinar o que cada agrupamento significa no contexto do problema


Aprendizado não-supervisionado

- **Clusterização**



Aprendizado não-supervisionado

- Regras associativas



Manipulação análise e visualização

- O aprendizado de máquina requer **preparação** da base de dados
 - Carregamento de dados de diferentes formatos
 - Manipulação de dados: limpeza, cálculos estatísticos, transformação, etc.
 - Visualização da informação
- Pandas, numpy e matplotlib são módulos que realizam essas operações

