



Aprendizado de Máquina Supervisionado

Tópicos



Agenda

- Breve introdução de aprendizado supervisionado
- Árvore de Decisão
 - Estrutura da árvore de decisão;
 - Entropia e ganho de informação
- Redes Neurais Artificiais
 - Neurônio Artificial;
 - *Perceptron* de Múltipla Camadas;
 - *Forward e Backpropagation*.
- Matriz de Confusão
- Métricas

Aprendizado de Máquina

Supervisionado



- Os algoritmos de aprendizagem relacionam uma saída com uma entrada com base em dados *rotulados*.


Matematica	Fund_computacao	Tec_computacao	Total	Especialidade
16	22	12	50	metodologias e técnicas de computação
4	16	8	28	engenharia de software
4	13	7	24	sistemas de informação
6	15	11	32	computação gráfica
12	20	11	43	sistemas de computação

Aprendizado de Máquina

Supervisionado



- Os algoritmos de aprendizagem relacionam uma saída com uma entrada com base em dados *rotulados*.




Algoritmos de classificação



- Objetivo é prever uma **classe** ou **rótulo** associado com uma variável de entrada contendo determinados atributos.
- O algoritmo é treinado com um conjunto de dados:
 - classes conhecidas, podendo estes dados estar divididos em somente duas (**classificação binária**) ou em várias classes (classificação multiclasse).

Árvore de Decisão

O que é?



Uma árvore de decisão é utilizado para classificação. Isto é, pode ser usado para prever categorias discretas (sim ou não, por exemplo) e para prever valores numéricos (o valor do lucro em reais).

Árvore de Decisão

Curiosidade



- É um algoritmos mais conhecido entre os algoritmos de *machine learning*;
- A sua estrutura e a composição do algoritmo é similar à de um fluxograma:
 - Etapas fáceis de visualizar e entender.

Árvore de Decisão

Curiosidade



- Além de uma boa técnica com bons resultados, é também uma ótima abordagem para uma compreensão melhor de como funciona o **aprendizado de máquina**.
- O método mais conhecido de ML.
 - Uma árvore pega emprestada uma noção de tomada de decisões que está muito presente em outras áreas, por isso, é mais acessível.

Vou assistir aula na universidade hoje?



Árvore de Decisão



- O grande trabalho da árvore é justamente encontrar os nós que vão ser encaixados em cada posição.
 - Quem será o nó raiz?
 - Depois, quem será o nó da esquerda? E o da direita?
- É preciso realizar alguns importantes cálculos:
 - **Ganho da informação;**
 - **Entropia.**

Árvore de Decisão

Entropia



- A **entropia** é uma medida de incerteza ou impureza em um conjunto de dados.
- No contexto de árvores de decisão, ela quantifica a aleatoriedade ou a desordem dos dados. A fórmula da entropia para um conjunto de dados é:

$$\text{Entropia}(S) = - \sum_{i=1}^n p_i \log_2(p_i)$$

Árvore de Decisão

Ganho da informação



- O **ganho de informação** é uma métrica usada para decidir qual **atributo** deve ser usado para dividir os dados em cada nó da árvore.
- Ele mede a redução na entropia ao dividir os dados com base em um atributo. A ideia é escolher o atributo que resulta na maior redução de incerteza.

$$\text{Ganho de Informação}(S, A) = \text{Entropia}(S) - \sum_{v \in \text{Valores}(A)} \frac{|S_v|}{|S|} \text{Entropia}(S_v)$$

Árvore de Decisão

Exemplos de aplicações



- Diagnóstico de doenças;
 - Identificar doenças a partir de informações cedidas ao algoritmo como treinamento.
- Previsão de empréstimos;
 - **Esse é um problema de regressão, pois requer uma informação numérica como saída.** O sistema vai entender como a base de dados está organizada de acordo com os atributos e criar um modelo capaz de fazer essa previsão.



Árvore de Decisão


Exemplos de aplicações



- Análise de sentimentos;
 - Não é incomum ver também aplicações na área da análise de sentimentos, subcategoria do campo de **PLN**.
- Previsão de saída de funcionários;
 - O RH saber quando um funcionário está quase saindo da empresa por insatisfação. Com a análise de dados sobre cada um, o modelo entende a base de dados e consegue realizar uma predição, ou seja, uma classificação.


Outros algoritmos de classificação





KNN

Support Vector Machine



SVM

Support Vector Machine

Preparação dos dados



Preparação

Divisão da base: Treino e teste



- Os dados de **treinamento** são empregados na indução e no **ajuste** do modelo.
- Os de **teste** simulam a apresentação de **objetos novos** ao preditor, os quais **não foram vistos em sua indução**.
- Os dados são divididos em conjuntos de treino e teste.
 - Geralmente utiliza 80% dos dados para treino e 20% para teste.

Exemplo

Processo de treinamento



Realização do Teste




Avaliação dos Modelos


Desempenho




- Subconjuntos são disjuntos para assegurar que as medidas de desempenho sejam obtidas a partir de um conjunto de exemplos diferente daquele usado no aprendizado.
- Alguns dos principais métodos de amostragem existentes, são:




(a) *Holdout*



(b) *Amostragem aleatória*



(c) *Validação cruzada*




(d) *Bootstrap*

Avaliação dos Modelos



- No caso dos procedimentos que envolvem médias de desempenho, devem-se reportar também os valores de **desvio padrão** associados.
- Para reportar **estimativas** mais precisas do **desempenho** esperado do algoritmo nesses casos, deve-se então apresentar algum intervalo de confiança para a média calculada, que irá envolver também o desvio padrão obtido.



De maneira geral, isso é realizado pela comunidade reportando ao menos os valores de média e desvio padrão dos experimentos realizados.

Importante!



Métricas



Tabela 10.1 Matriz de confusão para um problema com duas classes

		Classe predita	
		+	-
Classe verdadeira	+	VP	FN
	-	FP	VN

- **VP** corresponde ao número de **verdadeiros positivos**, ou seja, o número de exemplos da classe positiva classificados corretamente.
- **VN** corresponde ao número de **verdadeiros negativos**, ou seja, o número de exemplos da classe negativa classificados corretamente.
- **FP** corresponde ao número de **falsos positivos**, ou seja, o número de exemplos cuja classe verdadeira é negativa, mas que foram classificados incorretamente como pertencentes à classe positiva.
- **FN** corresponde ao número de **falsos negativos**, ou seja, o número de exemplos pertencentes originalmente à classe positiva que foram incorretamente preditos como da classe negativa.

Matriz de confusão

$$\bullet n = VP + VN + FP + FN$$

Acurácia total: calculada pela soma dos valores da diagonal principal da matriz, dividida pela soma dos valores de todos os elementos da matriz

$$Acurácia = \frac{VP + VN}{N}$$

Precisão: proporção de exemplos positivos classificados corretamente entre todos aqueles preditos como positivos

$$Precisão = \frac{VP}{VP + FP}$$

Recall: corresponde à taxa de acerto na classe positiva. Também é chamada de taxa de verdadeiros positivos

$$Recall = \frac{VP}{VP + FN}$$


F1-score: Essa métrica representa a média harmônica entre as métricas de Precisão e de Recall.

$$f1 - score = \frac{2 * Precisão * Recall}{Precisão + Recall}$$

Título

Subtítulo

Recomendações





Contate-nos



lid@ufpa.br



@lid.ufpa